

รายงานการสำรวจและตรวจสอบข้อมูล

1. ข้อมูลตัวอย่างดิบ

Index	Employee_ID	Age	Salary
0	101	25	50,000
1	102	30	60,000
2	103	NaN	55,000
3	104	45	NaN
4	101	25	50,000
5	105	35	65,000
6	106	200	40,000
7	107	28	48,000

2. ผลการวิเคราะห์และตรวจสอบคุณภาพข้อมูล

จากการใช้คำสั่งตรวจสอบทางสถิติและโครงสร้างข้อมูลของ Pandas ได้ผลลัพธ์การวิเคราะห์ดังนี้:

มิติของข้อมูล (Data Shape): 8 แถว (Rows), 5 คอลัมน์ (Columns)

ข้อมูลที่ขาดหาย (Missing Values):

คอลัมน์ Age พบ 1 ค่า

คอลัมน์ Salary พบ 1 ค่า

ข้อมูลซ้ำซ้อน (Duplicate Records): พบแถวซ้ำกันสมบูรณ์ทั้งหมด 1 แถว (Index 4 ซ้ำกับ Index 0:

Employee_ID 101)

ค่าผิดปกติ (Outliers): พบค่าอายุสูงผิดปกติในแถว Index 6 (Age= 200) ซึ่งเป็นข้อมูลที่ไม่ถูกต้องตามความเป็นจริง

การกระจายตัวของ Target Class (Left_Company):

No (ยังอยู่กับบริษัท): 5 คน (62.5%)

Yes (ลาออกจากบริษัท): 3 คน (37.5%)

3. ซอร์สโค้ดการประมวลผล

```
import pandas as pd
import numpy as np

data = {
    'Employee_ID': [101, 102, 103, 104, 101, 105, 106, 107],
    'Age': [25, 30, np.nan, 45, 25, 35, 200, 28], # มี missing และ outlier (อายุ 200)
    'Salary': [50000, 60000, 55000, np.nan, 50000, 65000, 40000, 48000], # มี missing
    'Department': ['IT', 'HR', 'IT', 'Marketing', 'IT', 'HR', 'IT', 'Marketing'],
    'Left_Company': ['No', 'Yes', 'No', 'No', 'No', 'Yes', 'No', 'Yes'] # Target Class
}
df = pd.DataFrame(data)
```

```
print("--- Data Shape ---")
print(df.shape)
print("\n")

print("--- Data Types ---")
print(df.dtypes)
print("\n")

print("--- Summary Statistics ---")
print(df.describe(include='all'))
print("\n")

print("--- Missing Values ---")
print(df.isnull().sum())
print("\n")

print("--- Duplicate Records ---")
print(f"Total duplicate rows: {df.duplicated().sum()}")
print("\n")

print("--- Class Distribution (Left_Company) ---")
print(df['Left_Company'].value_counts())
```