

รายงานการทำความสะอาดข้อมูล

1. ข้อมูลก่อนการทำความสะอาด (Before Cleaning Dataset)

Index	Employee_ID	Age	Salary	Department	Left_Company
0	101	25.0	50,000.00	IT	No
1	102	30.0	60,000.00	HR	Yes
2	103	NaN	55,000.00	IT	No
3	104	45.0	NaN	Marketing	No
4	101	25.0	50,000.00	IT	No
5	105	35.0	65,000.00	HR	Yes
6	106	200.0	40,000.00	IT	No
7	107	200.0	48,000.00	Marketing	Yes

2. ขั้นตอนการทำความสะอาดข้อมูล (Data Cleaning Pipeline)

การดำเนินการตามซอร์สโค้ดในโปรแกรม

จัดการค่า Missing ในคอลัมน์ Age: แทนค่าว่าง (NaN) ด้วยค่ามัธยฐาน (median) ของอายุ

จัดการค่า Missing ในคอลัมน์ Salary: แทนค่าว่าง (NaN) ด้วยค่าเฉลี่ย (mean) ของเงินเดือน

จัดการข้อมูลซ้ำซ้อน (Duplicates): ลบแถวที่ซ้ำกันสมบูรณ์ด้วย drop_duplicates() และทำการจัดลำดับดัชนีใหม่ด้วย reset_index(drop=True)

จัดการค่าผิดปกติ (Outliers): ตรวจสอบค่าอายุที่มากกว่า 100 (Age > 100) และแทนที่ด้วยค่ามัธยฐาน (median) ของอายุ

แปลงชนิดข้อมูล (Data Type Casting): แปลงคอลัมน์ Employee_ID ให้เป็นข้อความ (string) เพื่อป้องกันการนำไปคำนวณทางสถิติที่ไม่มีความหมาย

3. ซอร์สโค้ดการทำความสะอาดข้อมูล (Source Code)

```
import pandas as pd
import numpy as np
```

```
print("--- Before Cleaning ---")
print(df)
print("-" * 50)

df['Age'] = df['Age'].fillna(df['Age'].median())

df['Salary'] = df['Salary'].fillna(df['Salary'].mean())

df = df.drop_duplicates().reset_index(drop=True)

median_age = df['Age'].median()
df.loc[df['Age'] > 100, 'Age'] = median_age

df['Employee_ID'] = df['Employee_ID'].astype(str)

print("--- After Cleaning ---")
print(df)
print("\n--- Remaining Missing Values ---")
print(df.isnull().sum())
```

4. ข้อมูลหลังการทำความสะอาด (After Cleaning Dataset)

Index	Employee_ID	Age	Salary	Department	Left_Company
0	101	25.0	50,000.00	IT	No
1	102	30.0	60,000.00	HR	Yes
2	103	30.0	55,000.00	IT	No
3	104	45.0	52,571.43	Marketing	No
4	105	35.0	65,000.00	HR	Yes
5	106	30.0	40,000.00	IT	No
6	107	28.0	48,000.00	Marketing	Yes

5. ผลการตรวจสอบความสมบูรณ์ของข้อมูล (Data Integrity Audit)

ค่าว่างคงเหลือ (Remaining Missing Values): พบ 0 ค่า ในทุกคอลัมน์ (ความสมบูรณ์ 100%)

จำนวนแถวข้อมูลคงเหลือ: เหลือ 7 แถว (ลบแถวซ้ำออก 1 แถว)

ชนิดข้อมูล (Data Types): Employee_ID ถูกเปลี่ยนเป็น object/str เรียบร้อยแล้ว